



**UNIVERSITÀ
DEGLI STUDI
DI TRIESTE**

Dipartimento di Ingegneria e Architettura

CORSO DI LAUREA
Ingegneria elettronica e informatica

PROVA FINALE

Summary of
“Explaining Genetic Programming Trees using
Large Language Models”

Laureando: Marco Civran
IN0501392

Relatore: Prof. Eric Medvet

ANNO ACCADEMICO 2025 - 2026

Introduzione e Obiettivi

Il presente elaborato riassume l'articolo di Maddigan P., Lensen A., Xue B. (2024). "Explaining Genetic Programming Trees using Large Language Models". [arXiv:2403.03397](https://arxiv.org/abs/2403.03397).

L'articolo tratta l'argomento del Genetic Programming (GP). Nello specifico si concentra su metodi di Non-Linear Dimensionality Reduction (GP-NLDR) ovvero i metodi che riducono il numero di dimensioni (feature) di un dataset, componendo nuove dimensioni che si basano sulle feature originali.

L'articolo mira a produrre un sistema in grado di spiegare i risultati del processo GP-NLDR attraverso l'utilizzo di Large Language Models (LLMs) come ChatGPT-3.5 di OpenAI. Questi chatbot vengono poi customizzati attraverso prompt engineering e l'utilizzo di Retrieval Augmented Generation (RAG) per fornire risposte più adatte all'*end-user* e più corrette nel contesto del dataset. Inoltre, dando un contesto più completo alla domanda, diminuisce la probabilità di allucinazioni.

Ogni nuova dimensione contenuta nell'embedding finale è rappresentata da un singolo albero GP, nel quale è presente un sottoinsieme degli attributi originali del dataset. I dataset moderni possono avere migliaia di features, che rendono l'albero molto grande e complesso, quindi incomprensibile ad una buona parte degli end-user.

Il quesito posto nell'articolo riguarda la possibilità di rendere comprensibili i risultati del processo di GP-NLDR a categorie di utenti eterogenee, utilizzando un chatbot basato su LLM all'interno di un sistema eXplainable AI (XAI).

Gli autori dimostrano che l'integrazione di prompt engineering e RAG nel sistema GP4NLDR consente spiegazioni accurate e accessibili, seppur con alcuni limiti legati alla complessità degli alberi e alla qualità del contesto fornito dall'utente.

Contesto e Motivazione

Il lavoro si inserisce in un filone precedente dedicato alla spiegabilità tramite Genetic Programming. In particolare, l'articolo di Mei et al. (2022) analizza le principali tecniche di XAI basate su GP, evidenziando il potenziale degli alberi simbolici come strumenti interpretabili. Il presente articolo si differenzia da questo approccio introducendo un LLM come interfaccia di conversazione destinata anche a utenti non esperti.

L'articolo presenta anche una rassegna di studi passati riguardanti tecniche di XAI applicate su diversi ambiti e fa notare la presenza di ulteriori articoli sul miglioramento della spiegabilità di GP, anche utilizzando chatbot specifici per tale applicazione.

Gli autori non individuano, nella letteratura da loro considerata, studi che utilizzino LLM all'interno dei propri sistemi; infatti, questi studi aumentano la comprensione per utenti esperti ma limitano le categorie di utenti in grado di comprendere la spiegazione.

Un altro punto a favore dell'utilizzo di chatbot come ChatGPT è l'importanza di un linguaggio naturale (dal punto di vista psicologico) ed il ruolo importantissimo che ha per le persone nell'assimilare le spiegazioni. Un linguaggio naturale in grado di spiegare al meglio un concetto genera fiducia e trasparenza verso il risultato prodotto dal GP, evitando la sindrome della black-box.

Metodologia

Per tradurre questi principi in un sistema, lo studio introduce GP4NLDR, un'architettura web-based composta da una User Interface grafica intuitiva e chatbot basati su LLMs, in modo che possa essere utilizzato da qualsiasi categoria di utente e con diverse applicazioni di GP-NLDR come GP-MAL, GP-MAL2, UMAP cost e NRMSE.

Inizialmente l'utente seleziona i parametri del processo (dataset, numero di individui per generazione, numero di generazioni, dimensione finale, funzione di fitness e metodo di controllo della crescita dell'albero).

Eseguito il processo, il sistema mostra il risultato insieme alla rappresentazione di ogni dimensione attraverso l'albero GP, contenente tutti i parametri che vanno a influenzare tale dimensione, un plot della funzione di fitness ed il chatbot.

Qui entra in gioco l'importante ruolo del pacchetto di informazioni iniziali che forniscono al chatbot un contesto completo del dataset, del risultato e del metodo applicato, oltre a mitigare il rischio di incomprensioni o allucinazioni. Questo pacchetto include informazioni:

1. sul dataset
2. sui parametri della run GP-NLDR
3. sulle feature utilizzate negli alberi
4. sulle metriche di qualità dell'embedding
5. sulle caratteristiche delle nuove dimensioni generate

A ciò si aggiunge un limite massimo di parole per le risposte, così da mantenere concisione e coerenza.

Siccome ChatGPT-3.5 è stato addestrato con dati fino al 2021, non conosce tutte le tecniche GP-NLDR recenti, per ovviare a questo problema il sistema utilizza RAG: un sistema in grado di recuperare informazioni rilevanti da un vector store costruito da articoli scientifici fondamentali per la conoscenza del dominio (GP-MAL, GP-MAL2, UMAP cost e

NRMSE). Il vector store viene attivato dal sistema quando l'utente utilizza una delle parole chiave (es. "umap" o "gpml2") recuperando passaggi importanti dagli articoli e inserendoli nel prompt. L'iniezione di contesto tramite RAG riduce significativamente la probabilità di allucinazioni.

Si fa notare che LLM più recenti come GPT-4 offrono una capacità di ragionamento superiore e una migliore gestione del contesto. Tuttavia, il sistema rimane compatibile con GPT-3.5 per garantire accessibilità.

Esempi e Risultati

La valutazione del sistema avviene analizzando 3 diversi dataset riguardanti contesti molto diversi e dimensionalità altrettanto variabili.

Il primo esempio utilizza un dataset di vini, con un numero moderato di feature e quindi un albero generato dal processo di GP-NLDR relativamente compatto. Questo esempio è ideale per mettere alla prova il chatbot nella descrizione generale dell'operazione eseguita e nella spiegazione in dettaglio di elementi specifici del dominio. Inoltre, ci mostra un esempio di domanda soggettiva sul risultato, alla quale il chatbot risponde principalmente in maniera oggettiva, mostrando la riduzione drastica di dimensioni e la leggera caduta in accuratezza.

Il secondo esempio utilizza un dataset di malattie dermatologiche, raddoppiando il numero di features presenti nel primo dataset e mostra come il chatbot sia in grado di capire le domande fatte anche utilizzando parole diverse da quelle usate nel dataset, questo avviene grazie alla conoscenza generale del LLM. Inoltre, gli viene chiesto di fare un confronto tra due tecniche di GP-NLDR, questa è un'informazione che il chatbot non possiede, quindi evita di dare una risposta concreta per evitare di fare allucinazioni.

Per mettere alla prova i limiti del sistema l'ultimo esempio utilizza un dataset di immagini, con un numero di features superiore al 1000, ognuna con un nome simbolico privo di significato contestuale. In questo caso gli alberi delle 2 dimensioni prodotte sono quasi impossibili da interpretare manualmente, ma il chatbot è comunque in grado di identificare le features più influenti e spiegarne il comportamento generale, anche utilizzando lingue diverse nella stessa conversazione. Qua emergono i primi limiti del sistema e le risposte diventano più generiche, ma il chatbot fornisce comunque risposte coerenti e dimostra una notevole robustezza multilingue.

Attraverso questi esempi si analizzano molteplici tipi di dataset:

- Dataset di piccole dimensioni (13 features) fino a dataset di grandi dimensioni (1024 features), con parametri aventi nomi descrittivi e non descrittivi.

- Utilizzo di diverse impostazioni di fitness, numero di dimensioni finali, numero di generazioni
- Contesti che spaziano dal riconoscimento di vino, malattie dermatologiche e riconoscimento immagini

In questi esempi viene richiesto al chatbot di:

- utilizzare parole chiave presenti nel RAG
- utilizzare terminologie diverse da quelle usate nel dataset
- gestire nomi delle feature descrittivi o meno
- gestione dei cali di accuratezza della soluzione (da 0.9868 a 0.6375)
- rispondere a domande soggettive, come la qualità dei risultati
- capacità di multilinguismo

Punti di Forza e Limitazioni

Sulla base di questi risultati si conferma l'efficacia del sistema, soprattutto quando il contesto fornito è sufficientemente ricco, dimostrandosi un passo avanti nel campo delle XAI.

Alcuni tra i punti di forza sono:

- l'usabilità e accessibilità dell'interfaccia web
- l'adattabilità del sistema al linguaggio naturale per i diversi tipi di utenti
- la riduzione di allucinazioni grazie al RAG
- la capacità di analizzare alberi GP complessi

Alcuni limiti sono:

- le risposte scarse in caso di contesto insufficiente
- mancanza di una soluzione definitiva per eliminare le allucinazioni
- rischi legati alla privacy dei dati, qualora l'utente inserisca informazioni sensibili nella conversazione
- generalmente la dipendenza dalla qualità del prompt fornito dall'utente

Tra le possibili migliorie suggerite dagli esempi ci sono:

- l'aggiunta di prompt dinamici che si adattano alle caratteristiche dell'albero GP prodotto
- l'utilizzo di LLM con maggiori garanzie di privacy
- l'aggiunta di ulteriori metodi di controllo al RAG

Una possibile ricerca futura può consistere nel verificare, attraverso end-user reali con livelli di comprensione diversi, se le spiegazioni risultano effettivamente più comprensibili rispetto alle spiegazioni tradizionali.

Conclusioni

Alla luce di questi elementi, lo studio presenta GP4NLDR come la prima interfaccia web in grado di combinare GP-NLDR con un chatbot basato su LLM per fornire spiegazioni in linguaggio più naturale possibile a quanti più utenti possibili, seguendo un approccio centrato sulla comprensione dell'utente finale.

Gli autori hanno dimostrato che tale sistema è in grado di spiegare i risultati del processo GP-NLDR attraverso l'utilizzo di LLM, fornendo spiegazioni più complete che aumentano l'affidabilità e la trasparenza dei risultati del processo di GP.

Partendo da questo paper si aprono strade verso nuovi ambiti di ricerca come la spiegazione di altri tipi di GP o l'utilizzo di AI generative per migliorare la comprensione e la trasparenza dei complessi sistemi di AI.

Riferimenti Bibliografici

- Maddigan P., Lensen A., Xue B. (2024) - [*Explaining Genetic Programming Trees using Large Language Models*](#). arXiv:2403.03397
- Mei Y., Chen Q., Lensen A., Xue B., Zhang M. (2022) - [*Explainable artificial intelligence by genetic programming: A survey*](#), IEEE Transactions on Evolutionary Computation, vol. 27, no. 3, pp. 621–641